


RL-Praktikum – Thema 6

Was lernen Q-Funktionen in modellfreiem Reinforcement Learning wirklich? — Status & Ergebnisse

1. Aktueller Stand

Wir haben drei modellfreie RL-Algorithmen (DQN, SAC, TD3) in zwei unterschiedlichen Benchmark-Umgebungen trainiert: DQN auf CartPole-v1, SAC und TD3 auf Pendulum-v1. Die Reward-Kurven zeigen, dass alle drei Agenten stabil lernen, bevor wir mit der eigentlichen Analyse der Q-Funktionen beginnen.

2. Ergebnisse



DQN (CartPole, linkes Panel) startet bei niedrigen Rewards (ca. 10-60), verbleibt dort bis etwa 30.000 Timesteps und steigt danach deutlich auf ein Niveau von ca. 150-250 (mit einzelnen Ausreißern bis knapp 370) — ein klares Lernsignal, auch wenn die maximal mögliche Episodenlänge (500) noch nicht durchgehend erreicht wird. SAC und TD3 (Pendulum, rechtes Panel) starten bei stark negativen Werten (bis ca. -1800), was einem anfänglich unkontrollierten Pendel entspricht, und konvergieren bereits nach wenigen tausend Timesteps zu deutlich kleineren negativen Werten (meist zwischen 0 und -300) — dem typischen, eingeregelten Bereich für Pendulum-v1. Beide Kurven zeigen ein klares Lernsignal; SAC und TD3 verhalten sich dabei sehr ähnlich.

3. Herausforderungen

- **Rauschen in den Reward-Kurven:** Auch nach der Konvergenz schwanken die Episoden-Rewards stark. Das ist zunächst normales Verhalten (Exploration, stochastische Dynamik) — es lässt sich aus der Reward-Kurve allein aber nicht unterscheiden, ob dieses Rauschen harmlos ist oder auf eine tatsächlich instabile Q-Funktion zurückgeht.

- **Unterschiedliche Reward-Skalen:** CartPole (additiv, positiv, max. 500) und Pendulum (quadratische Kostenfunktion, immer negativ) sind nicht direkt vergleichbar — ein direkter Vergleich der absoluten Reward-Werte zwischen den Umgebungen ist nicht aussagekräftig.
- **Reward-Kurve zeigt nur Policy-Performance, nicht die Q-Funktion selbst:** Bisher sehen wir nur, wie gut die Agenten handeln, nicht, wie korrekt ihre internen Werteinschätzungen (Q-Werte) tatsächlich sind. Genau das ist aber die eigentliche Forschungsfrage.