

Applied Reinforcement Learning - Report Übung 3

Zustandsverläufe: Ground Truth vs. Forecast

Abbildung 1 zeigt für jede Datenmenge $N \in \{50, 100, 200, 500, 1000\}$ die vier Zustandsgrößen (`cartPos`, `cartVel`, `pendPos`, `pendVel`) im Vergleich zwischen Ground Truth und dem autoregressiven 50-Schritte-Forecast.

Bei $N = 200, 500$ und 1000 liegen Forecast und Ground Truth über nahezu den gesamten Rollout-Horizont eng beieinander. Bei $N = 50$ driftet vor allem `cartPos` und `pendPos` ab etwa Zeitschritt 15–25 moderat weg. Bei $N = 100$ sind `cartPos`/`cartVel` nahezu perfekt getroffen, während `pendPos` ab $\sim$ Zeitschritt 15 die stärkste Abweichung aller Modelle zeigt und auch `pendVel` ab $t > 40$ deutlich abweicht. Der Fehler konzentriert sich bei $N = 100$ also fast ausschließlich auf die Pendel-bezogenen Größen – ein Hinweis darauf, dass Winkel und Winkelgeschwindigkeit des Pendels die instabilste und am schwersten zu lernende Systemkomponente sind.

Fehlerverlauf über die Zeit

Der Fehler ist zu Rollout-Beginn für alle N nahezu null und wächst danach an, da das Modell zunehmend auf seine eigenen, leicht fehlerhaften Vorhersagen als Input für den nächsten Schritt zurückgreift (*compounding error*). Dieses Anwachsen ist bei $N = 50$ (`cartPos`, `pendPos`) und $N = 100$ (`pendPos`, `pendVel`) deutlich sichtbar; bei $N = 200, 500$ und 1000 bleibt der Fehler über nahezu den gesamten Horizont niedrig.

Vergleich über die Datenmengen N

Es ergibt sich folgende Rangfolge der Zukunftsgeneralisierung (am wenigsten bis am stärksten drift-behaftet):

$$N=200 \approx N=1000 \approx N=500 \ll N=50 < N=100$$

Auffällig: nicht $N = 50$, sondern $N = 100$ zeigt die größte Abweichung (konzentriert auf `pendPos`) – die Datenmenge allein ist also nicht der einzige Faktor; Zufallseffekte beim Training (Initialisierung, Auswahl der längsten Episode) spielen ebenfalls eine Rolle. Ab $N = 200$ ist ein stabiler Sättigungsbereich erkennbar: größere Datenmengen liefern durchgehend präzise Vorhersagen mit kaum sichtbaren Abweichungen.

Kurze Interpretation: Ab wann driftet der Forecast sichtbar weg?

Bei $N = 50$ beginnt das Wegdriften ab Zeitschritt ~ 15 –25 (`cartPos`/`pendPos`). Bei $N = 100$ setzt die Abweichung bei `pendPos` ähnlich früh ein, wächst aber deutlich stärker; `pendVel` driftet zusätzlich ab $t \approx 40$. Bei $N \geq 200$ ist über den gesamten Horizont kein vergleichbares Wegdriften zu beobachten.

Insgesamt bestätigt sich: mehr Trainingsdaten führen tendenziell zu einem stabileren Dynamik-Modell, der Zusammenhang ist aber nicht perfekt monoton. Ab $N \approx 200$ ist eine Sättigung erreicht; im Bereich $N = 50$ –100 beeinflussen Zufallseffekte die Rollout-Qualität stärker, weshalb $N = 100$ hier sogar schlechter abschneidet als $N = 50$ (Zustandsgröße `pendPos`).

Q1: State Trends - Ground Truth vs. 50-Step Forecast Across Dataset Sizes




Abbildung 1: Ground Truth vs. Modell-Forecast für alle vier Zustandsgrößen, aufgeteilt nach Datenmenge N . Die schattierte Fläche markiert die Abweichung zwischen Forecast und Ground Truth.