

Applied Reinforcement Learning - Report Übung 3

Zustandsverläufe: Ground Truth vs. Forecast

Abbildung 1 zeigt für jede Datenmenge $N \in \{50, 100, 200, 500, 1000\}$ die vier Zustandsgrößen (`cartPos`, `cartVel`, `pendPos`, `pendVel`) im Vergleich zwischen Ground Truth und dem autoregressiven 50-Schritte-Forecast.

Bei $N = 200, 500$ und 1000 liegen Forecast und Ground Truth über nahezu den gesamten Rollout-Horizont eng beieinander. Bei $N = 50$ driftet vor allem `cartPos` und `pendPos` ab etwa Zeitschritt 15–25 moderat weg. Bei $N = 100$ sind `cartPos`/`cartVel` nahezu perfekt getroffen, während `pendPos` ab $\sim$ Zeitschritt 15 die stärkste Abweichung aller Modelle zeigt und auch `pendVel` ab $t > 40$ deutlich abweicht. Der Fehler konzentriert sich bei $N = 100$ also fast ausschließlich auf die Pendel-bezogenen Größen – ein Hinweis darauf, dass Winkel und Winkelgeschwindigkeit des Pendels die instabilste und am schwersten zu lernende Systemkomponente sind.

Fehlerverlauf über die Zeit

Der Fehler ist zu Rollout-Beginn für alle N nahezu null und wächst danach an, da das Modell zunehmend auf seine eigenen, leicht fehlerhaften Vorhersagen als Input für den nächsten Schritt zurückgreift (*compounding error*). Dieses Anwachsen ist bei $N = 50$ (`cartPos`, `pendPos`) und $N = 100$ (`pendPos`, `pendVel`) deutlich sichtbar; bei $N = 200, 500$ und 1000 bleibt der Fehler über nahezu den gesamten Horizont niedrig.

Vergleich über die Datenmengen N

Es ergibt sich folgende Rangfolge der Zukunftsgeneralisierung (am wenigsten bis am stärksten drift-behaftet):

$$N=200 \approx N=1000 \approx N=500 \ll N=50 < N=100$$

Auffällig: nicht $N = 50$, sondern $N = 100$ zeigt die größte Abweichung (konzentriert auf `pendPos`) – die Datenmenge allein ist also nicht der einzige Faktor; Zufallseffekte beim Training (Initialisierung, Auswahl der längsten Episode) spielen ebenfalls eine Rolle. Ab $N = 200$ ist ein stabiler Sättigungsbereich erkennbar: größere Datenmengen liefern durchgehend präzise Vorhersagen mit kaum sichtbaren Abweichungen.

Kurze Interpretation: Ab wann driftet der Forecast sichtbar weg?

Bei $N = 50$ beginnt das Wegdriften ab Zeitschritt ~ 15 –25 (`cartPos`/`pendPos`). Bei $N = 100$ setzt die Abweichung bei `pendPos` ähnlich früh ein, wächst aber deutlich stärker; `pendVel` driftet zusätzlich ab $t \approx 40$. Bei $N \geq 200$ ist über den gesamten Horizont kein vergleichbares Wegdriften zu beobachten.

Insgesamt bestätigt sich: mehr Trainingsdaten führen tendenziell zu einem stabileren Dynamik-Modell, der Zusammenhang ist aber nicht perfekt monoton. Ab $N \approx 200$ ist eine Sättigung erreicht; im Bereich $N = 50$ –100 beeinflussen Zufallseffekte die Rollout-Qualität stärker, weshalb $N = 100$ hier sogar schlechter abschneidet als $N = 50$ (Zustandsgröße `pendPos`).

Q1: State Trends - Ground Truth vs. 50-Step Forecast Across Dataset Sizes





Abbildung 1: Ground Truth vs. Modell-Forecast für alle vier Zustandsgrößen, aufgeteilt nach Datenmenge N . Die schattierte Fläche markiert die Abweichung zwischen Forecast und Ground Truth.

Aufgabe 4.2 — Vergleich Modellqualität vs. Policyqualität



N	Rollout-MAE	Mittlere Performanz	Std
50	0.005611	472.70	46.72
100	0.030178	500.00	0.00
200	0.012375	483.85	70.40
500	0.010853	500.00	0.00
1000	0.002705	500.00	0.00

Es zeigt sich **kein konsistenter Zusammenhang** zwischen Modell- und Policy-Qualität:

- N=1000 hat den niedrigsten Rollout-Fehler (0.0027) und erreicht die maximale Performanz (500) — hier passt die Erwartung.
- N=100 hat dagegen den **höchsten** Rollout-Fehler (0.0302), erreicht aber trotzdem die maximale Performanz (500) — widerspricht der Erwartung.
- N=50 hat einen der niedrigsten Rollout-Fehler (0.0056), aber die **schlechteste** Performanz (472.70, hohe Streuung).
- N=200 liegt bei mittlerem Rollout-Fehler, zeigt aber die schwächste und instabilste Performanz (483.85, Std=70.40).

Insgesamt: 3 von 5 Policies (N=100, 500, 1000) erreichen den Decken-Effekt von 500 Schritten trotz unterschiedlicher Modellqualität, während N=50 und N=200 darunter liegen

— ohne dass ihre Modellfehler das erklären.

Aufgabe 4.3 — Diskussion der Leitfragen

1. Ab welcher Datenmenge entstehen deutliche Verbesserungen? Kein sauberer monotoner Trend: $N=50 \rightarrow 100$ verbessert die Performanz deutlich (472.7 $\rightarrow$ 500), aber $N=200$ fällt wieder ab (483.85). Erst ab $N=500$ ist die maximale Performanz stabil erreicht.

2. Gibt es Sättigungseffekte bei Modell- oder Policy-Qualität? Bei der Policy ja — ab $N=500$ liegt die Performanz konstant beim technischen Maximum (500, Std=0). Bei der Modellqualität kein klarer Sättigungspunkt erkennbar; der Fehler schwankt uneinheitlich über N (kein monotoner Abfall).

3. Welche typischen Fehler zeigen sich bei kleinen Datensätzen? $N=50$ und $N=200$ zeigen die größte Streuung zwischen den 20 Startzuständen (Std=46.7 bzw. 70.4) — die Policy ist also nicht durchgängig stabil, sondern versagt bei einem Teil der Startzustände deutlich früher. Das deutet auf ungleichmäßige Abdeckung des Zustandsraums im Dynamik-Modell hin.

4. Spiegelt gute Forecast-Qualität automatisch gute Policy-Performanz wider? Nein. $N=100$ widerlegt das direkt: schlechtester Rollout-Fehler, aber perfekte Policy-Performanz. Ein guter Forecast ist demnach **nicht hinreichend und nicht notwendig** für eine gute Policy in diesem Setup — vermutlich weil PPO auch mit einem ungenauen Modell noch eine ausreichend stabile Strategie lernen kann, solange die für die Balance relevanten Zustandsbereiche halbwegs erfasst sind.