

Übung: Model-based Reinforcement Learning

Ziel der Übung

Sie untersuchen den Einfluss der gesampelten Datenmenge auf die Qualität des gelernten Dynamik-Modells und die Performanz einer darauf trainierten Policy.

Die Aufgaben sind bewusst getrennt:

Aufgabe 1: nur Dynamik-Modell (ohne Policy-Training)

Aufgabe 2/3/4: Policy-Training und Evaluation

Aufgabe 1: Dynamik-Modell trainieren und Zukunftsgeneralisierung analysieren

Zu verwendendes Notebook: Model-based RL - Dynamic Model for Cartpole

1.1) Datensätze mit unterschiedlicher Größe erzeugen

Erstellen Sie mehrere Trainingsdatensätze mit unterschiedlicher Datenmenge (in Bezug auf Anzahl gesampelter Episoden):

N = {50, 100, 200, 500, 1000} Episoden

1.2) Für jede Datenmenge ein Dynamik-Modell trainieren

Trainieren Sie für jede Datenmenge ein eigenes Dynamik-Modell mit identischem Modellaufbau und vergleichbaren Hyperparametern.

1.3) Zukunftsgeneralisierung pro Dynamik-Modell

Für jedes trainierte Dynamik-Modell führen Sie folgende Untersuchung durch:

1. Nehmen Sie aus den jeweiligen Trainingsdaten die längste Episode (idealerweise > 50 Schritte).
2. Initialisieren Sie mit dem Startzustand dieser Episode.
3. Verwenden Sie die in dieser Episode aufgezeichneten Aktionen für die ersten 50 Schritte als feste Aktionsfolge.
4. Lassen Sie das Dynamik-Modell für diese 50 Schritte einen Forecast (Roll-Out) erzeugen
5. Vergleichen Sie den Forecast mit den Ground-Truth-Zuständen aus der gesampelten Simulation (derselbe Episodenabschnitt).

1.4) Auswertung zu Aufgabe 1

Erstellen Sie mindestens:

- Zustandsverläufe: Ground Truth vs. Forecast (pro Zustandsgröße)
- Fehlerverlauf über die Zeit (z. B. absoluter Fehler pro Schritt)
- Vergleich über die Datenmengen N (welches Modell generalisiert am besten?)
- Kurze Interpretation: Ab wann driftet der Forecast sichtbar weg?

Aufgabe 2: Policy-Training auf Basis der Dynamik-Modelle

Zu verwendendes Notebook: Model-based RL - PPO Policy Training

2.1 Environment pro Dynamik-Modell verwenden

Nutzen Sie je Datenmenge N das zugehörige trainierte Dynamik-Modell als Environment-Basis.

2.2 PPO-Policy trainieren und abspeichern (mit N im Dateinamen)

Trainieren Sie für jedes Dynamik-Modell eine PPO-Policy mit konsistenten Trainingsparametern, sodass die Ergebnisse vergleichbar bleiben.

Aufgabe 3: Standardisierte Evaluation der Policies

3.1 Feste Startzustände definieren

Definieren Sie 20 unterschiedliche Startzustände, z.B. durch `env.reset()` mit entsprechendem seed.

3.2 Faire Vergleichbarkeit sicherstellen

Innerhalb einer Evaluationsrunde müssen für alle zu vergleichenden Policies exakt dieselben 20 Startzustände verwendet werden.

3.3 Performanz messen

Führen Sie pro Startzustand eine Episode aus und messen Sie die Performanz (→ Episodenlänge bis zum „terminate“ oder „done“).

Berechnen Sie für jede Policy den Durchschnitt über die 20 Episoden.

Aufgabe 4: Gesamtauswertung und Diskussion

Zu verwendendes Notebook: Model-based RL - PPO Policy Training

4.1 Ergebnisdarstellung

Erstellen Sie mindestens:

- Tabelle: Datenmenge N vs. mittlere Policy-Performanz
- Diagramm: N auf x-Achse, mittlere Performanz auf y-Achse
- Optional: Streuung (z. B. Standardabweichung über mehrere Läufe)

4.2 Vergleich Modellqualität vs. Policyqualität

Diskutieren Sie den Zusammenhang zwischen:

Zukunftsgeneralisierung aus Aufgabe 1 und Policy-Performanz aus Aufgabe 3.

4.3 Leitfragen für die Diskussion

1. Ab welcher Datenmenge entstehen deutliche Verbesserungen?
2. Gibt es Sättigungseffekte bei Modell- oder Policy-Qualität?
3. Welche typischen Fehler zeigen sich bei kleinen Datensätzen?
4. Spiegelt gute Forecast-Qualität automatisch gute Policy-Performanz wider?